

# MANUAL TÉCNICO

GRUPO #12

01/03/2022

## PRÁCTICA NO.2

Josselyn Vanessa Polanco Gameros 201602676  
Oscar Alfredo Llamas Lemus 201602625  
Jose Alejandro Santizo Cotto 201709309  
Alison Cristina Leiva Paredes 201700378





# INTRODUCCIÓN

## INICIANDO...

Para la elaboración de la aplicación que se encarga de leer páginas web y analizar su contenido, se utilizó el lenguaje de programación Golang, para la lectura de la página web se hizo un scraping y se utilizaron rutinas para ingresar trabajos a la cola y para iniciar el scraper en segundo plano.

A continuación, se muestra más a detalle el código y el manejo del scraper y rutinas.

# INICIO...

## MENÚ EN CONSOLA

En la función main, existe un método llamado "LimpiarPantalla" que, como su nombre lo indica, sirve para limpiar la consola, luego de ello, se capturan los valores ingresados por el usuario en consola para poder empezar el flujo del proyecto según los datos ingresados por el usuario.

```
func main() {  
  
    LimpiarPantalla()  
  
    fmt.Println(string(getColor("cyan")), "- Ingrese cantidad de monos")  
    fmt.Print(string(getColor("green")), "SOPE$2 ")  
    fmt.Print(string(getColor("yellow")), ">> ")  
    fmt.Scanln(&Lectura)  
    Lectura = strings.TrimSuffix(Lectura, "/")  
    Lectura = strings.TrimSpace(Lectura)  
    MonkeysAmmount, _ := strconv.ParseInt(Lectura, 10, 64)  
  
    fmt.Println("")  
    fmt.Println(string(getColor("cyan")), "- Ingrese tamaño de la cola")  
    fmt.Print(string(getColor("green")), "SOPE$2 ")  
    fmt.Print(string(getColor("yellow")), ">> ")  
    fmt.Scanln(&Lectura)  
    Lectura = strings.TrimSuffix(Lectura, "/")  
    Lectura = strings.TrimSpace(Lectura)  
    QueueSize, _ := strconv.ParseInt(Lectura, 10, 64)
```

# INICIANDO FLUJO

## MI PRIMER JOB

Al terminar de capturar los valores ingresados por el usuario, se crea el primer trabajo con los primeros valores que el usuario ingreso, como el Nr, que será el número de enlaces que se utilizarán al inicio, el URL de la página para construir nuestro archivo JSON.

Luego de llenar el struct, se llama al método SetScraper que iniciará con el flujo del programa, este tiene 3 parámetros, el struct, el número de monos y el tamaño de la cola.

```
myFirstJob := Work{
    SHAPadre: "0",
    URL:      EntryPoint,
    NR:       NrValue,
}

SetScraper(&myFirstJob, MonkeysAmmount, QueueSize)

// Realizando un scrapper de prueba, esto se haria iterando en
//RunScraper(NrValue, EntryPoint, "mono_01", "0")
fmt.Println(string(getColor("green")), "Scraping terminado. Pre
fmt.Scanln(&Lectura)

fmt.Print(string(getColor("yellow")), "Hasta la próxima! :)")
```

# SCRAPER

## INICIALIZACIÓN DE SCRAPER

En el método que se mencionó anteriormente, se crea un canal donde pasarán los trabajos, con un tamaño de 1000, luego de ello se crea un arreglo de monos con el tamaño que el usuario asignó.

Al inicializar estas dos variables, se crea un for para llenar los structs de monos con su respectivo ID y su disponibilidad, al inicio es true.

```
// Setear parametros de scrapper
func SetScraper(firstJob *Work, monosValue int64, queueSize int64) {

    // haciendo un canal donde pasaran Works
    jobs := make(chan Work, 1000)

    // Haciendo un arreglo donde estan mis N monos
    myMonkeys = make([]Monkey, monosValue)

    // Seteando ID para cada mono
    for i := 0; i < int(monosValue); i++ {
        myMonkeys[i].ID = "monkey_0" + strconv.Itoa(i+1) //monkey_01, monkey_02
        myMonkeys[i].Disponibile = true
    }

    // Creando cola de trabajos
    myQueue = &Cache{Slots: make([]Work, 0, queueSize)}
    myQueue.Mu.Lock()
    // agregando el trabajo inicial a la cola
    myQueue.Slots = append(myQueue.Slots, *firstJob)
    myQueue.Mu.Unlock()

    // Go routine para Leer canal y agregar trabajos a la cola
    go CheckJobs(&jobs, myQueue)
```

# SCRAPER

## UTILIZANDO RUTINAS Y VERIFICANDO LA COLA

Al tener todos los structs de los monos con sus respectivos valores inicializados, se crea la cola de trabajos con el tamaño que el usuario definió, se bloquea la cola para que no haya ninguna alteración mientras se escribe en ella, y luego se inserta el trabajo a dicha cola, al finalizar, se desbloquea la cola para que pueda seguir trabajando.

```
293 // Creando cola de trabajos
294 myQueue = &Cache{Slots: make([]Work, 0, queueSize)}
295 myQueue.Mu.Lock()
296 // agregando el trabajo inicial a la cola
297 myQueue.Slots = append(myQueue.Slots, *firstJob)
298 myQueue.Mu.Unlock()
299
300 // Go routine para leer canal y agregar trabajos a la cola
301 go CheckJobs(&jobs, myQueue)
302
303 for len(myQueue.Slots) > 0 {
304
305     if len(myQueue.Slots) > 0 {
306
307         newJob := DeQueue()
308         searchMonkey := true
309         monkeyIndex := -1
310
311         for searchMonkey {
312
313             monkeyIndex = FindAvailableMoney(&myMonkeys)
314             if monkeyIndex != -1 {
315                 searchMonkey = false
316             }
317
318         }
319
320         // si llego aqui, es porque hay un mono disponible
321         myMonkeys[monkeyIndex].Disponible = false
322         monkeyID := myMonkeys[monkeyIndex].ID
323         go RunScraper(newJob.NR, newJob.URL, monkeyID, newJob.SHAPadre, jobs, monkeyIndex)
```

# SCRAPER

## COLA DE TRABAJOS Y RUTINAS

Se llama a la rutina CheckJobs para verificar si hay trabajos nuevos para agregarlos a la cola, luego de ello se saca un nuevo trabajo de la cola y se verifica si el mono está disponible llamando al método FindAvailableMoney

```
293 // Creando cola de trabajos
294 myQueue = &Cache{Slots: make([]Work, 0, queueSize)}
295 myQueue.Mu.Lock()
296 // agregando el trabajo inicial a la cola
297 myQueue.Slots = append(myQueue.Slots, *firstJob)
298 myQueue.Mu.Unlock()
299
300 // Go routine para leer canal y agregar trabajos a la cola
301 go CheckJobs(&jobs, myQueue)
302
303 for len(myQueue.Slots) > 0 {
304
305     if len(myQueue.Slots) > 0 {
306
307         newJob := DeQueue()
308         searchMonkey := true
309         monkeyIndex := -1
310
311         for searchMonkey {
312
313             monkeyIndex = FindAvailableMoney(&myMonkeys)
314             if monkeyIndex != -1 {
315                 searchMonkey = false
316             }
317
318         }
319
320         // si llego aqui, es porque hay un mono disponible
321         myMonkeys[monkeyIndex].Disponible = false
322         monkeyID := myMonkeys[monkeyIndex].ID
323         go RunScraper(newJob.NR, newJob.URL, monkeyID, newJob.SHAPadre, jobs, monkeyIndex)
```

# COLAS

## VERIFICAR SI HAY TRABAJOS NUEVOS

Método que verifica si hay un nuevo trabajo para agregar a la cola, si es así, se llama al método Queue para agregarlo a la cola de trabajo.

```
heckear constantemente si hay trabajos nuevos para agregar a la cola
|CheckJobs(canal *chan Work, cache *Cache) {
for SeguirScrapper {

    myJob := <-*chanal
    // fmt.Println("Se recibio un nuevo work en el canal")
    // fmt.Println(myJob)
    Queue(&myJob)
}
```



# COLAS Y PALABRAS

## FUNCIONES

El primer método agrega un trabajo a la cola, el segundo saca un trabajo de la cola y devuelve ese mismo trabajo, la tercera función verifica si un mono está disponible o no.

```
246 // Agregar un trabajo a la cola
247 func Queue(work *Work) {
248     if len(myQueue.Slots) < cap(myQueue.Slots) {
249         myQueue.Mu.Lock()
250         myQueue.Slots = append(myQueue.Slots, *work)
251         myQueue.Mu.Unlock()
252     }
253 }
254
255 // Quitar un trabajo de la cola
256 func DeQueue() *Work {
257     myQueue.Mu.Lock()
258     auxWork := myQueue.Slots[0] // x/2/3/4/5/...
259     myQueue.Slots = myQueue.Slots[1:]
260     myQueue.Mu.Unlock()
261
262     return &auxWork
263 }
264
265 // Buscar un mono disponible
266 func FindAvailableMoney(monos *[]Monkey) int {
267
268     for i, mono := range *monos {
269
270         if mono.Disponible {
271             return i
272         }
273     }
274
275     return -1
276 }
```

# RUN SCRAPER

## REALIZACIÓN DEL SCRAPER

Este método es el que extra la información de la página y llama al método de contador de palabras, se cuentan los enlaces que hay y se genera el SHA para cada work.

```
153 // Metodo para realizar el scrapping
154 /*
155  nr = numero de enlaces que debe buscar en la pagina
156  url = direccion de la pagina
157  mono = id del mono que esta haciendo el scrapping
158  origen = es el SHA del contenido de la pagina donde se
159  */
160 func RunScraper(nr int64, url string, mono string, orig
161
162     contenido := ""
163     var cantidadEnlaces int64 = 0
164     var contadorNR int64 = 0
165     var contentSHA string = ""
166     c := colly.NewCollector()
167
168     c.OnHTML("p", func(e *colly.HTMLElement) {
169         |     contenido += e.Text + "\n"
170     })
```

# RUN SCRAPER

## REALIZACIÓN DEL SCRAPER

Sección que busca los enlaces dentro de las etiquetas p, también se hace un foreach para buscar los enlaces y hacer un conteo de estos.

```
172 // Buscando todas los enlaces dentro de las etiquetas p
173 c.OnHTML("p", func(e *colly.HTMLInputElement) {
174
175     e.ForEach("p", func(_ int, text *colly.HTMLInputElement) {
176         contenido += text.Text + "\n"
177     })
178
179     h := sha1.New()
180     h.Write([]byte(contenido))
181     // variable con el SHA para el atributo SHAPadre de los nuevos works
182     contentSHA = hex.EncodeToString(h.Sum(nil))
183
184     e.ForEach("a[href]", func(_ int, elem *colly.HTMLInputElement) {
185         link := elem.Attr("href")
186         if elem.Request.AbsoluteURL(link) != "" {
187
188             cantidadEnlaces++
189
190             if nr > 0 && contadorNR < nr {
191
192                 // variable con el enlace para el nuevo work que se ingresara en la cola
193                 linkNuevoWork := elem.Request.AbsoluteURL(link)
194
195                 // variable con el valor de nr - 1
196                 newNR := nr - 1
197
198                 contadorNR++
199
200                 /* AQUI SE MANDARIAN LOS NUEVOS WORKS A LA COLA*/
201                 // fmt.Printf("Se encontro el enlace #%v: %s - nuevo Nr = %v \n ", contadorNR, linkNuevoWork, newNR)
202             }
172
```

# ARCHIVO JSON

## INSERTANDO ITEM EN JSON

Se llena el struct para ingresar un nuevo item al archivo JSON, luego de ello, se hace un conteo de palabras y se hace una breve pausa hasta que el mono esté disponible de nuevo.

```
JsonResult := Resultado{
    Origen:    origen,
    Palabras:  int64(WordCount(contenido)),
    Enlaces:   cantidadEnlaces,
    SHA:       contentSHA,
    URL:       url,
    Mono:      mono,
}

myResults = append(myResults, JsonResult)
contadorEscrituras++
numberOfMilliseconds := WordCount(contenido)

mensaje := fmt.Sprintf("El mono %s esta descansando", myMonkeys[mo
fmt.Println(string(getColor("yellow")), mensaje)
time.Sleep(time.Millisecond * time.Duration(numberOfMilliseconds) *
myMonkeys[monkeyIndex].Disponible = true
mensaje = fmt.Sprintf("El mono %s ya esta disponible", myMonkeys[m
fmt.Println(string(getColor("cyan")), mensaje)
}
```